

Федеральное государственное автономное
образовательное учреждение высшего образования
«Национальный исследовательский университет
ИТМО»

Факультет Информационных технологий и программирования

Типовой расчет по математической статистике

«Ковариация и регрессия. Построение выборочного
уравнения
линии регрессии»

Вариант 4

Васильков Дмитрий Алексеевич

М3215

Санкт-Петербург

2024 г.

Исходные данные:

y_j^* x_i^*	21	31	36	41
16	0	0	30	80
26	0	55	20	0
36	15	0	0	0

Ход работы:

Приступим к выполнению задания.

Сначала, при обработке нашей выборки предварительно проведем группировку значений X и Y подобно тому, как мы это делали в ТР1. При этом, для частичных интервалов $\Delta x_i = [x_{i-1}, x_i, i = 1, \dots, k]$ и $\Delta y_j = [y_{j-1}, y_j, j = 1, \dots, m]$ определим число элементов выборки n_{ij} , попавших в прямоугольник $\Delta x_i \times \Delta y_j$, и вычислим середины интервалов по формулам $x_i^* = \frac{x_{i-1} + x_i}{2}$, $y_j^* = \frac{y_{j-1} + y_j}{2}$. Все элементы выборки, попавшие в прямоугольник

$\Delta x_i \times \Delta y_j$, будем считать равными (x_i^*, y_j^*) , причем количество значений x_i^* будет равно $n_i = \sum_{j=1}^m n_{ij}$, а количество значений y_j^* будет равно $n_j = \sum_{i=1}^k n_{ij}$.

Объем выборки равен $n_i = \sum_{i=1}^k n_i = \sum_{j=1}^m n_j = \sum_{i=1}^k \sum_{j=1}^m n_{ij}$.

Занесем эти данные в таблицу:

y_j^* x_i^*	21	31	36	41	n_i
16	0	0	30	80	110
26	0	55	20	0	75
36	15	0	0	0	15
n_j	15	55	50	80	n=200

Теперь, выполним построение выборочного уравнения линии линейной регрессии по нашей таблице группированных данных.

Формула выборочного уравнения линии регрессии:

$$y(x) = \bar{Y}_n + r_n(X, Y) \frac{\sigma_n(Y)}{\sigma_n(X)} (x - \bar{X}_n). \quad (4)$$

Для расчета коэффициентов в выборочном уравнении линии регрессии (4) используют формулы:

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^k n_i x_i^*, \quad \bar{Y}_n = \frac{1}{n} \sum_{j=1}^m n_j y_j^*, \quad (5)$$

$$\sigma_n(X) = \sqrt{\frac{1}{n} \sum_{i=1}^k n_i (x_i^*)^2 - \bar{X}_n^2}, \quad \sigma_n(Y) = \sqrt{\frac{1}{n} \sum_{j=1}^m n_j (y_j^*)^2 - \bar{Y}_n^2}, \quad (6)$$

$$r_n(X, Y) = \frac{\sum_{i=1}^k \sum_{j=1}^m n_{ij} x_i^* y_j^* - n \cdot \bar{X}_n \cdot \bar{Y}_n}{n \cdot \sigma_n(X) \cdot \sigma_n(Y)}. \quad (7)$$

По формулам (5) находим:

$$\bar{X}_{200} = 21,25$$

$$\bar{Y}_{200} = 35,5$$

По формулам (6) находим:

$$\sigma_{200}(X) = 6,320$$

$$\sigma_{200}(Y) = 5,788$$

По формуле (7) находим:

$$r_{200}(X, Y) = -0,9193$$

Подставив найденные величины в формулу (4), получим искомое выборочное уравнение линейной регрессии Y на X:

$$y = 35,5 - 0,9193 \cdot \frac{5,788}{6,320} (x - 21,25)$$

Или окончательно:

$$y = 53,3907 - 0,841916 x \quad (8)$$

Сравним оценки условных математических ожиданий, вычисленные:

а) на основе последнего уравнения

б) по данным таблицы 7, полагая, как и ранее, $P(y_j^*) = p_j^* = n_{ij}/n_i$

Например, возьмем $x_i^* = 16$:

а) $E(Y|X = 16) = 53,3907 - 0,841916 * 16 = 39,920$

б) $E(Y|X = 16) = (30 * 36 + 80 * 41) / 110 = 39,636$

Как видно, соответствие удовлетворительное.

Заметим, что уравнения линейной регрессии (3) и выборочной линейной регрессии (4), (8) являются уравнениями, задающими прямую линию.

На этом выполнение типового расчета №2 **закончено**.